

Reporte Riesgo Crediticio

Autor: Alberth Pinco Bravo

Agosto de 2026

Resumen

El otorgamiento de crédito a perfiles con alta probabilidad de incumplimiento representa un riesgo financiero crítico para las entidades financieras. En este trabajo se desarrolló un modelo de clasificación para predecir el riesgo de impago en una cooperativa a partir de variables sociodemográficas y de comportamiento. A través del análisis exploratorio y la evaluación de importancia de características, se identificaron la edad, el número de préstamos activos y el nivel de ingresos como los factores más determinantes. Se entrenaron y evaluaron tres modelos de machine learning (Regresión Logística, Random Forest y XGBoost), seleccionando al XGBoost como el modelo óptimo al detectar de forma anticipada al 71 % de los clientes con riesgo de impago ($\text{Recall}=0.71$) y alcanzar un 84 % de fiabilidad en la clasificación de clientes seguros ($\text{Precision}(-)=0.84$), ofreciendo así una herramienta eficaz para mitigar pérdidas y optimizar el proceso de aprobación crediticia.

Contacto: alberthpinco@gmail.com

1. Análisis exploratorio

Para comenzar, es importante tener en cuenta el desequilibrio en la distribución de la variable objetivo ([Figura 1](#)), donde solo el 33% de los registros corresponden a clientes con riesgo de impago. Esto es de suma importancia para la etapa de modelado puesto que no queremos que se vea afectada la capacidad del algoritmo de identificar correctamente a la clase minoritaria.




Figura 1. Distribución de la variable Riesgo.

Al analizar la variable edad en función del riesgo de impago ([Tabla 1](#)), se observa que el grupo catalogado con riesgo presenta una edad promedio y mediana sustancialmente mayor (49 y 47 años, respectivamente) en comparación con el grupo sin riesgo (39 y 37 años), lo cual sugiere que la edad es una variable con capacidad de discriminación relevante para el modelo.

Tabla 1. Promedio y mediana de la edad según el riesgo.

Edad	Promedio	Mediana
Riesgo		
Si	49	47
No	39	37

Respecto a los ingresos, también se observa una diferencia en ambos grupos, en la cual, los clientes que presentan riesgo tienden a registrar ingresos moderadamente menores en comparación al grupo sin riesgo (véase [Figura 2](#)). En particular, el 50% central de los clientes con riesgo tiene ingresos entre 18,702 y 24,972 USD, mientras que para el grupo sin riesgo este rango oscila entre 21,066 y 29,265 USD (véase [Tabla 2](#)).




Figura 2. Distribución de la edad y los ingresos según el riesgo.

Tabla 2. Resumen estadístico de ingresos según el riesgo.

Ingresos	Promedio	Q1	Q3
Riesgo			
Si	23,546	18,702	24,972
No	27,231	21,066	29,265

En cuanto al número de préstamos activos, se observa una relación directa con el nivel de riesgo: a medida que este incrementa, la proporción de clientes con riesgo de impago pasa del 20 % (0 préstamos) al 50 % (3 préstamos), tal como se detalla en la [Tabla 3](#). Un comportamiento similar se evidencia con respecto al número de hijos, donde el riesgo relativo aumenta progresivamente a mayor carga familiar ([Figura 3](#)).

Tabla 3. Proporción de riesgo de impago según la cantidad de préstamos activos.

Préstamos	0	1	2	3
Riesgo				
Si	0.2	0.25	0.47	0.5
No	0.8	0.75	0.53	0.5




Figura 3. Distribución del riesgo de impago por número de préstamos e hijos.

2. Resultados

Se entrenaron tres modelos: una Regresión Logística, un Random Forest y un XGBoost, optimizando los hiperparámetros de cada uno mediante un Grid Search con validación cruzada. Posteriormente, se evaluó el desempeño de estos sobre el conjunto de prueba, cuyos resultados se detallan en la [Tabla 4](#).

A partir de estos datos, se evidencia que el XGBoost obtuvo el mejor desempeño general. Si bien comparte el mismo Recall (0.71) para la clase de riesgo que la Regresión Logística, el XGBoost demostró una superioridad cuantitativa al alcanzar una mayor Precision (0.57) y un mayor Roc-Auc (0.79), reduciendo así el número de falsos positivos y logrando un mejor equilibrio global (como se aprecia en la [Figura 4](#)).

Tabla 4. Desempeño de los modelos en el conjunto de prueba.

	Reg. Logística	Random Forest	XGBoost
Precision (—)	0.83	0.82	0.84
Precision (+)	0.55	0.55	0.57
Specificity	0.71	0.72	0.73
Recall	0.71	0.69	0.71
Roc-Auc	0.76	0.78	0.79




Figura 4. Matrices de confusión




Figura 5. Curva Roc del modelo XGBoost en el conjunto de prueba.

Para evaluar la explicabilidad del modelo finalmente escogido (XGBoost), se calculó la importancia de las variables mediante el método de permutación (véase [Figura 6](#)). Los resultados revelan que la edad es la variable de mayor peso predictivo, seguida del número de préstamos y los ingresos. Al permutar la edad, la métrica Roc-Auc sufre la mayor caída (cercana a 0.13), lo que ratifica que el perfil demográfico y el nivel de endeudamiento previo son los factores más determinantes para predecir el riesgo de impago en la cooperativa.




Figura 6. Importancia de las variables para el XGBoost basada en la caída del Roc-Auc.

3. Conclusiones

- La implementación del modelo XGBoost permite detectar de forma anticipada a 7 de cada 10 clientes con riesgo de impago ($\text{Recall} = 0.71$), alcanzando además un 84 % de fiabilidad en la clasificación de clientes de bajo riesgo ($\text{Precision}(-) = 0.84$).
- El análisis exploratorio y la evaluación de importancia por permutación confirmaron que la edad, el número de préstamos activos y el nivel de ingresos son los factores más determinantes para predecir el riesgo crediticio en la cooperativa.